$$\mathrm{SNR} = \frac{d_k}{W-1}, \qquad W = 2M + D + Q, \qquad M^{*} = c\,d_k - \frac{D+Q-1}{2}, \qquad c = \frac{1}{2\theta},$$

где W — число записей в состоянии в момент чтения, а θ — порог SNR, ниже которого чтение ошибается. При $Q = 8$ свободный член равен $-(D+7)/2$. Наклон c не зависит от D, а значит, и от длины последовательности. Свободный член от D зависит.

1. **Разложение чтения.** Запишите $S_t^{\top} q$ после W записей при $q = k_i$ как сумму сигнала и вектора помехи n.

(1)

$$S_w^T q_i = S_w^T \cdot K_i = \left(\sum_{j \le w} K_j v_j^T\right)^T K_i = \sum_{j \le w} \left(K_j v_j^T\right)^T K_i = \sum_{j \le w} v_j K_j^T K_i =$$

$$= \sum_{j \le w} (K_j^T K_i)\, v_j = K_i^T K_i\, v_i + \sum_{\substack{j \ne i \\ j \le w}} (K_j^T K_i) v_j = v_i + \sum_{\substack{j \ne i \\ j \le w}} (K_j^T K_i) \cdot v_j$$

$K_i^T K_i = 1$, т.к. $\|K\| = 1$

сигнал

вектор помехи

$$\Rightarrow n = \sum_{\substack{j \ne i \\ j \le w}} (K_j^T K_i) \cdot v_j$$

(2)

2. **Мощность помехи.** Мощность — матожидание квадрата нормы, $\mathbb{E}\|n\|^2$; SNR — отношение мощностей сигнала и помехи. Допущения:
   - ключи независимы и равномерно распределены на единичной сфере в $\mathbb{R}^{d_k}$;
   - значения не зависят от ключей, $\|v_j\| = 1$.

   Покажите, почему перекрёстные члены в $\|n\|^2$ в среднем равны нулю, и выведите $\mathbb{E}[(k_j^{\top} k_i)^2] = 1/d_k$.

$$\|n\|^2 = \left(\sum_{\substack{j \ne i \\ j \le w}} K_j^T K_i v_j\right)^T \cdot \sum_{\substack{l \ne i \\ l \le w}} K_l^T K_i v_l = \sum_{\substack{j \ne i \\ j \le w}} \left(K_j^T K_i v_j\right)^T \cdot \sum_{\substack{l \ne i \\ l \le w}} K_l^T K_i v_l =$$

$$= \sum_{\substack{j \ne i \\ j \le w}} v_j^T K_i^T \cdot K_j \cdot \sum_{\substack{l \ne i \\ l \le w}} K_l^T \cdot K_i v_l = \sum_{\substack{j \ne i \\ j \le w}} \sum_{\substack{l \ne i \\ l \le w}} v_j^T \cdot K_i^T \cdot K_j \cdot K_l^T \cdot K_i v_l =$$

$\|v\| = 1$

$$= \sum_{j \ne i} \sum_{l \ne i} (K_i^T \cdot K_j)(K_l^T \cdot K_i)\, v_j^T \cdot v_l = \sum_{\substack{j = l \\ j \ne i}} K_i^T \cdot K_j \cdot K_j^T \cdot K_i \cdot v_j^T \cdot v_j +$$

$$+ \sum_{\substack{j \ne l \ne i \\ j}} \sum_{\substack{j \ne l \ne i \\ l}} (K_i^T \cdot K_j)(K_l^T \cdot K_i)\, v_j^T \cdot v_l = (1) + (2)$$

$$\mathbb{E}\left[\|n\|^2\right] = \mathbb{E}[(1)] + \mathbb{E}[(2)]$$

1) $\mathbb{E}[(1)] = \sum_{\substack{j=l \\ j\neq i}} \mathbb{E}[K_i^T \cdot K_j \cdot K_j^T \cdot K_i] = \sum_{\substack{j=l \\ j\neq i}} \mathbb{E}\left[(K_j^T K_i)^T (K_j^T \cdot K_i)\right] =$

$= \sum_{\substack{j=l \\ j\neq i}} \mathbb{E}\left[(K_j^T K_i)^2\right] =$ {зафиксируем $K_i = (\underbrace{1, 0, \dots, 0}_{d_k})$, $K_j = (x_1, x_2, \dots, x_{d_k})$, $\sum_{t=1}^{d_k} x_t^2 = 1$, $\mathbb{E}\sum_{t=1}^{d_k} x_t^2 = \mathbb{E}1$} $=$

$= \sum_{\substack{j=l \\ j\neq i}} \mathbb{E}[x_{j1}^2] = \sum_{\substack{j=l \\ j\neq i}} \mathbb{E}\left[1 - \sum_{a=2}^{d_k} x_{ja}^2\right] \Rightarrow$ {$\mathbb{E}x_{j1}^2 = \mathbb{E}x_{j2}^2 = \dots = \mathbb{E}x_{jd_k}^2$ равномерность по среде} $=$

$A = \mathbb{E}x_{j1}^2$

$A = 1 - (d_k - 1)A \Rightarrow A = \frac{1}{d_k}$ – для 1-го ключа

$=$ $\sum_{\substack{j=l \\ j\neq i}} \mathbb{E}x_{j1}^2 = \frac{W-1}{d_k}$

2) $\mathbb{E}[(2)] = \sum_{\substack{j\neq l\neq i \\ j}} \sum_{\substack{j\neq l\neq i \\ l}} \mathbb{E}\left[(K_i^T \cdot K_j)(K_l^T \cdot K_i)\, v_j^T \cdot v_l\right] =$ {зафиксируем K_i, v_j, v_l} $=$

$= \sum_{\substack{j\neq l\neq i \\ j}} \sum_{\substack{j\neq l\neq \\ l}} \mathbb{E}\left[(K_i^T \cdot K_j)(K_l^T \cdot K_i)(v_j^T \cdot v_l) \,\middle|\, K_i, v_j, v_l\right] =$

$= \sum_{\substack{j\neq l\neq i \\ j}} \sum_{\substack{j\neq l\neq i \\ l}} \mathbb{E}[K_i^T K_j \mid K_i] \cdot \mathbb{E}[K_l^T K_i \mid K_i] \cdot (v_j^T \cdot v_l) =$

{ т.к. K_j и $-K_j$ равновероятны, то первое математическое ожидание равно нулю аналогично для второго

$= 0 \Rightarrow \mathbb{E}\|n\|^2 = \frac{W-1}{d_K}$

т.к. $P_{сигнала} = \mathbb{E}\|v_i\|^2 = 1 \Rightarrow SNR = \frac{d_K}{W-1}$

(3) 3. **Число записей W.** Укажите, для какого из Q запросов оно считается, и объясните, почему паддинг в него не входит.

$W = 2 \cdot M + D + Q$ — после 8 запроса и его записи

Паддинг исключаем, т.к. модель допуска была нацелена делать его вклад нулевым

(4) 4. **Прямая теории.** Найдите наибольшее M, при котором выполняется $\mathrm{SNR} \geq \theta$.

$$\frac{d_K}{W-1} \geq \theta \qquad \frac{d_K}{2M+D+Q-1} \geq \theta$$

$$d_K \geq 2\theta M + D\theta + Q\theta - \theta$$

$$d_K + \theta - D\theta - Q\theta \geq 2\theta M$$

$$\frac{d_K}{2\theta} - \frac{D+Q-1}{2} \geq M \qquad c = \frac{1}{2\theta}$$

Т.е. $M^* = c \cdot d_K - \frac{D+Q-1}{2}$

(5) 5. **Дельта-правило.** Покажите, что при $\beta_t = 1$ и $\|k_t\| = 1$ чтение $S_t^\top k_t$ возвращает ровно v_t. Предскажите, выше или ниже прямой ветви `linear` лежат точки M^* ветви `delta`.

$$S_t = \left(I - \beta_t K_t K_t^\top\right) S_{t-1} + \beta_t K_t v_t^\top$$

$$S_t^T K_t = \left(\left(I - K_t K_t^T\right) S_{t-1} + K_t v_t^T\right)^T \cdot K_t =$$

$$= S_{t-1}^T \left(I - K_t \cdot K_t^T\right) K_t + v_t \cdot \underbrace{K_t^T \cdot K_t}_{\|K_t\|=1} =$$

$$= S_{t-1}^T \left(K_t - K_t \underbrace{K_t^T \cdot K_t}_{\|\ \|=1}\right) + v_t = v_t$$

я ожидаю, что M* у delta будет выше, тк перезапись в ней уменьшит накопление лишних вкладов и снизит помехи, у linear они только накопятся

(6)

В условии задания сказано, что ключи имеют единичную норму, значения - нет. Равномерность ключей по сфере не гарантирована, тк направления задаются обучаемыми эмбеддингами. Независимость ключей не гарантируется из-за операции свертки, также как и независимость значений от ключей, тк их получают из представлений одной последовательности.

(7) Возьмём $\alpha = 0{,}5 \Rightarrow c = 1$

• Чтение теряет надёжность, когда средняя мощность помехи равна 2-ум мощностям сигнала.

при $D = 0$

$M^* = d_k - 3{,}5$

Возьмём $d_k = 16 \Rightarrow M^* = 12{,}5 \Rightarrow$

Если модель на $M = 17$ парах ответит на половину, то гипотеза не выполняется

• При добавлении D дистракторов сдвиг M^*

будет на $-D/2$. Проверяется при фикс. d_k и разном D.

- При добавлении R токенов M^* не изменится. Иначе — иногда опровергнута.

Отчёт

---

2 Дизайн

Исследовалась задача MQAR с восемью запросами на последовательность. Получил ветвь `linear` и два seed: 331181 и 362194. В переборе менялись число пар $M \in [8, 32]$ и размерность ключа $d_k \in \{8, 10, 12, 16\}$. Дистракторов не было, число паддинг-токенов подбиралось так, чтобы длина всей последовательности оставалась равно 128.

Архитектура и обучение во всех запусках были одинаковыми: два блока внимания с MLP, ширина модели 128, одна голова, $d_v = 64$, AdamW, батч 64 и 2000 шагов. Обучающая выборка содержала 32768 последовательностей, отложенная — 2048. Точка M^* определялась как наибольшее M, при котором точность на отложенной выборке не ниже 0.5.

Перед перебором softmax-контроль прошёл проверку: отложенная точность при $M = 8$ и $M = 32$ составила 1.000 в обеих точках, что выше требуемых 0.95. Отдельный softmax-контроль основной сетки при $d_k = 16$ дал 1.000 и 0.999 соответственно. Для сравнения использовалась эталонная сетка `reduced` для ветвей `linear` и `delta` с seed 0 и 1.

3 Результат

После отработки скрипта на эталонных данных МНК:

- `linear`, seed 0: $c = 1.94,\ b = -8.34$;
- `linear`, seed 1: $c = 2.4,\ b = -9.6$;
- `delta`, seed 0: $c = 1.03,\ b = 10.17$;
- `delta`, seed 1: $c = 0.91,\ b = 9.49$.

Для моих запусков:

- `linear`, seed 331181: $c = 1.2,\ b = 3.2$;
- `linear`, seed 362194: c и b определить нельзя — после исключения цензурированных точек осталась одна точка.

Гипотеза не подтвердилась, предполагалось $c = 1,\ b = -3.5$, то есть модель на 12–13 парах ответит на половину при $d_k = 16$. Однако для seed 331181 измерено $M^* = 24$, а для seed 362194 точка цензурирована сверху: модель проходит порог даже при $M = 32$, поэтому точное M^* неизвестно. При этом оценённый по первому seed наклон $c = 1.2$ близок к предсказанному, то есть гипотеза о наклоне по этому seed не опровергнута, но свободный член $b = 3.2$ заметно отличается от -3.5. По второму seed прямую построить нельзя, поэтому устойчивость оценки наклона между этими seed проверить не удалось.

Для эталонных seed размах коэффициентов c и b составил соответственно 0.46 и 1.26 у `linear`, 0.11 и 0.69 у `delta`. Мои точки M^* при $d_k = 12, 16$ попадают в диапазон эталонного `linear`, а при $d_k = 8, 10$ лежат выше него. В эталоне `delta` обычно имеет большее M^*, чем `linear`; при $d_k = 16$ порядок зависит от seed.

Помимо точки при $d_k = 16$, у seed 362194 отброшены точки снизу при $d_k = 8, 10$. Флаг `non_monotone` есть у этого же seed при $d_k = 10, 12$ и в эталоне у `linear`, seed 0, при $d_k = 8$; эти скачки могут быть связаны с неустойчивостью обучения. При $d_k = 16$, seed 331181, от $M = 24$ к $M = 28$ обучающая точность падает с 0.594 до 0.45, а отложенная — с 0.538 до 0.404. Обе убывают, ыoftmax остаётся около единицы.

МНК без свободного члена принудительно провела бы прямые через $(0, 0)$, изменила оценку c и хуже описала измеренные точки.

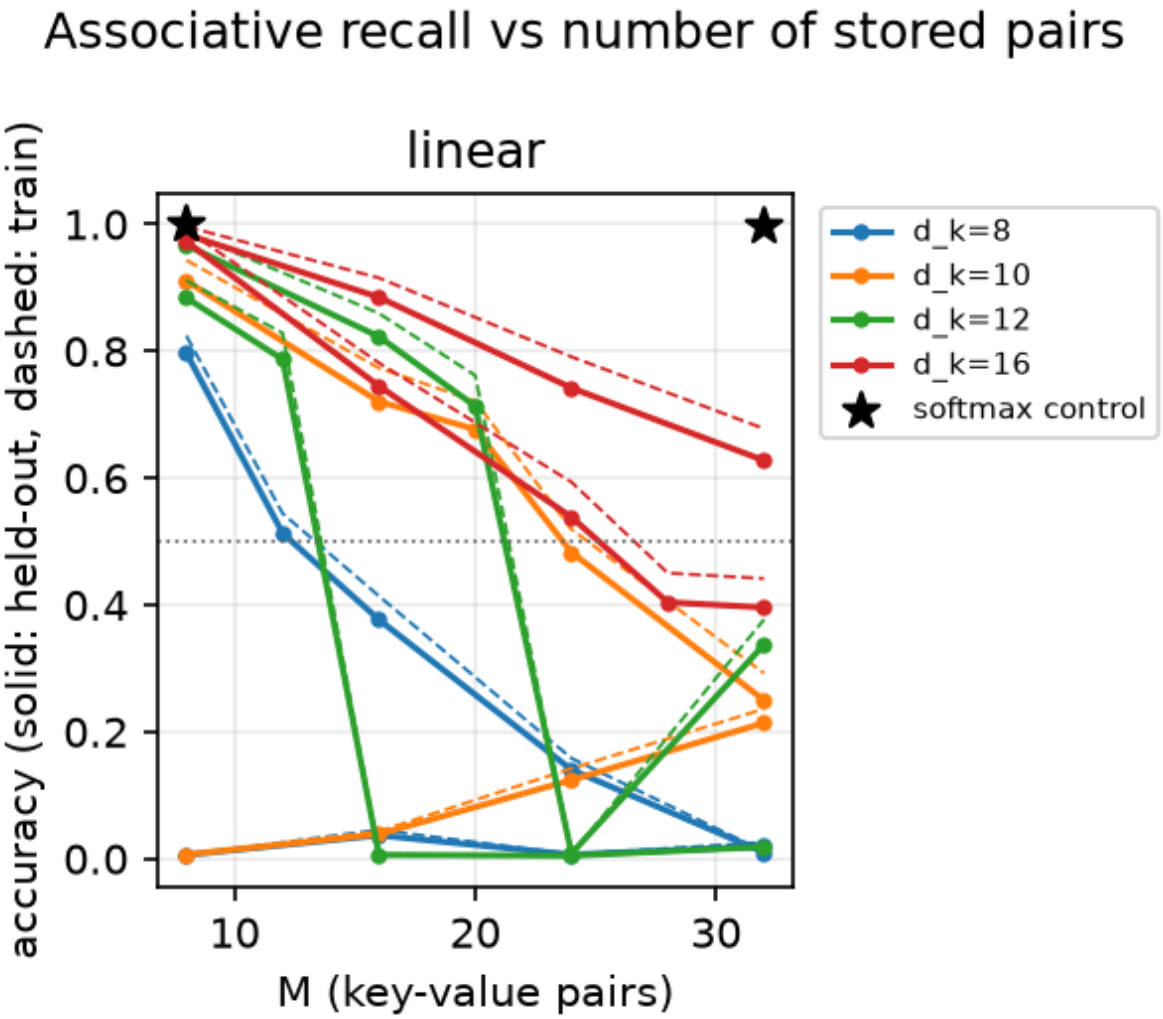


Рис. 1: При росте числа пар точность linear снижается, softmax остаётся близким к единице.

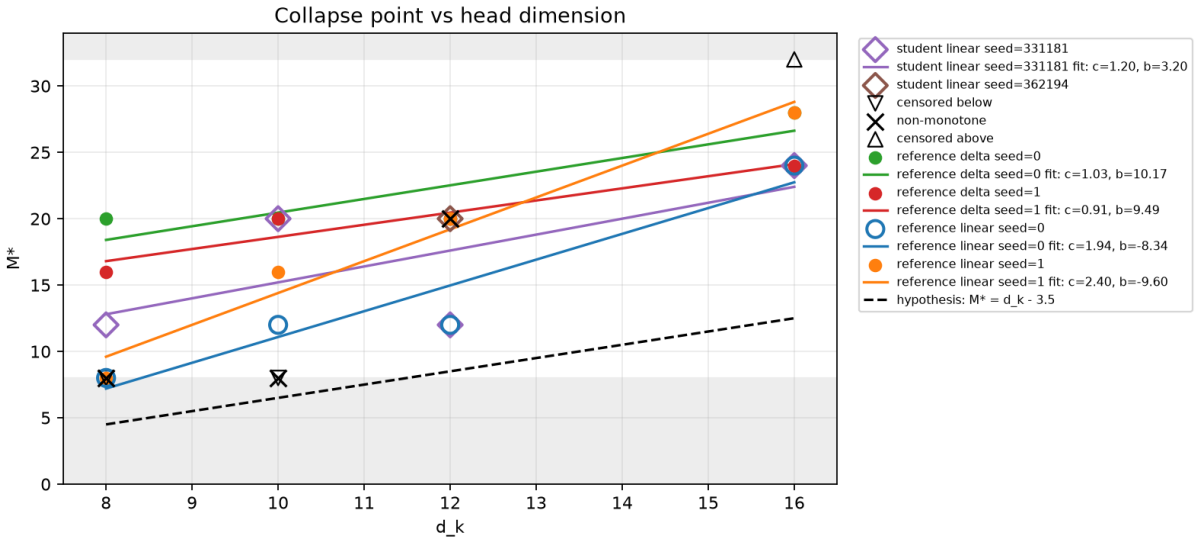


Рис. 2: Измеренные точки M^*, прямые МНК и предсказанная зависимость от d_k.

4 Расширение

Выбрал вариант a: проверка размера чанка и добавления паддинга. Во всех запусках использовались `linear`, $d_k = 16$, $M = 16$, seed 331181 и $D = 0$.

При $N = 128$ и размерах чанка $L = 16, 32, 64$ отложенная точность составила соответственно $0.758,\ 0.745,\ 0.838$. При фиксированном $L = 32$ увеличение паддинга с $P = 24$ до $P = 88$, снизило отложенную точность с 0.92 до 0.745. Гипотеза об отсутствии эффекта паддинга не подтвердилась.

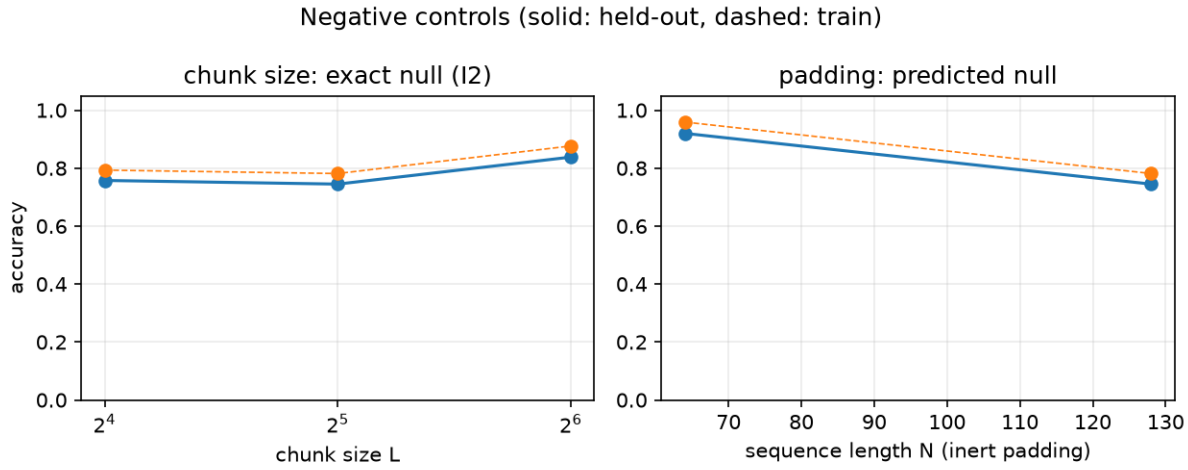


Рис. 3: При изменении длины последовательности за счёт паддинга отложенная точность изменилась с 0.92 до 0.745.

Размер чанка определяет, на какие части разбивается последовательность. При одинаковых весах и точных вычислениях разные размеры чанка дают один и тот же ответ. В `fp32` ответы могут немного различаться из-за округления.

В эксперименте модели для разных размеров чанка обучались отдельно. Их итоговая точность различалась максимум на 0.093. По этим запускам не установить, какая часть разницы связана с округлением, а какая — с различиями в ходе обучения.

В проверке паддинга точность изменилась на 0.175, поэтому предсказание о его нулевом эффекте не подтвердилось. Оба результаты были изменены, если бы поменялся только один – его бы и стоило исследовать, то есть при различии чанков – численные погрешности, а в случае паддингов – разные его длины.

5 Два числа состояния

У linear и delta attention состояние одной головы имеет размер $d_k d_v$. При $d_k = 16$ и $d_v = 64$ это $16 \cdot 64 \cdot 4 = 4096$ байт (4 КБ) на слой. Новый токен обновляет это состояние, поэтому его размер не растёт: прирост составляет 0 байт на токен.

Softmax attention хранит ключ и значение каждого токена. При $N = 128$ это $128(16+64) \cdot 4 = 40960$ байт (40 КБ) на слой; каждый следующий токен добавляет $(16 + 64) \cdot 4 = 320$ байт.

6 Три формы

В рекуррентной форме каждый токен сначала обновляет состояние $S_t = S_{t-1} + k_t v_t^\top$, а затем читает из него $o_t = S_t^\top q_t$. В чанковой форме между чанками передаётся та же матрица S: она содержит вклады всех токенов до текущего чанка. Для всех запросов внутри чанка эти вклады считаются

сразу как QS. Вклады самого чанка считаются как

$$O = QS + \big(M \odot (QK^\top)\big)V, \qquad S_{\text{out}} = S + K^\top V.$$

Маска M оставляет в строке i только позиции $j \le i$: чтобы не заглядывать в будущее. Диагональ включена, поскольку токен сначала записывает собственные k_i, v_i в состояние, а затем получает ответ.

Рекуррентная форма делает меньше вычислений, но требует последовательно обработать все N токенов. На каждом шаге работы мало, видеокарта простаивает. Параллельная форма считает взаимодействия токенов матричными умножениями: операций больше, гпу загружено, однако дорого гонять память. Чанковая форма совмещает эти подходы: между чанками остаётся примерно N/L последовательных переходов состояния, а внутри чанка длины L вычисления выполняются матричными умножениями.

7 Что изменило бы вывод

Предсказание $c = 1,\ b = -3.5$ не согласуется с измеренным $M^* = 24$ при $d_k = 16$: оно давало бы $M^* \approx 12.5$. Вывод по наклону пока ненадёжен. Для seed 331181 получено $c = 1.20$, а для seed 362194 прямую построить нельзя из-за censored у точки. Повторный перебор с несколькими seed и хотя бы двумя нецензурированными точками для каждого показал бы, устойчиво ли расхождение с предсказанием.

Предсказанный сдвиг M^* на $-D/2$ при добавлении дистракторов не проверялся, так как выбрал расширение a. Проверка паддинга была проведена, и точность изменилась с 0.920 до 0.745, то есть эффект есть, но можно замерить с еще несколькими seed, чтобы понять, есть ли тут реальный эффект.